Οικονομικό Πανεπιστήμιο Αθηνών

Τμήμα Στατιστικής

Αριθμητικές Μέθοδοι στην Στατιστική
Splines και Νευρωνικά Δίκτυα Kolmogorov-Arnold

Πέτρος Χριστοδούλου
s6210114
Διδάσκοντες : Α. Γιαννακόπουλος
Μάιος 2026

Περίληψη

Βασικό σκοπό της Μηχανικής Μάθησης αποτελεί η προσέγγιση πολύπλοκων συναρτήσεων, οι οποίες καλούνται να συνδέουν δεδομένα με μία ζητούμενη μεταβλητή. Με τη σύνδεση αυτή το μοντέλο αποκτά την ικανότητα γενίκευσης σε άγνωστα δεδομένα και έτσι μπορούν να υπολογίζονται προβλέψεις για αυτά. Ωστόσο, ενώ τα παραδοσιακά μοντέλα επιτυγχάνουν υψηλές αποδόσεις, αντιμετωπίζουν προκλήσεις σε υψηλές διαστάσεις. Για την επίλυση του προβλήματος αυτού δημιουργήθηκαν τα πρώτα νευρωνικά δίκτυα βασισμένα στο θεώρημα Kolmogorov-Arnold, τα οποία όμως λόγω μαθηματικών περιορισμών δεν μπόρεσαν να αντιμετωπίσουν το πρόβλημα αυτό. Στην παρούσα εργασία θα συζητηθεί πώς η χρήση των splines στα νευρωνικά δίκτυα Kolmogorov-Arnold βοήθησε στην εξάλειψη των περιορισμών που υπήρχαν και έτσι ολοκληρώθηκε η ιδέα για μια καινοτόμο αρχιτεκτονική για το πώς τα μοντέλα ερμηνεύουν τα δεδομένα.

Περιεχόμενα

1 Εισαγωγή **1**
1.1 Τι είναι τα Splines . . . 1
1.2 Τι είναι το Θεώρημα Kolmogorov-Arnold . . . 2
1.2.1 Αδυναμίες του Θεωρήματος Kolmogorov-Arnold . . . 2

2 Νευρωνικά Δίκτυα Kolmogorov-Arnold **3**
2.1 Δημιουργία Νευρωνικών Δικτύων Kolmogorov-Arnold . . . 3
2.2 Αρχιτεκτονική των KANs . . . 3
2.3 Διαφορές Αρχιτεκτονικών και Σύγκριση KANs με MLPs . . . 5
2.3.1 Διαφορές Αρχιτεκτονικών . . . 5
2.3.2 Σύγκριση KANs με MLPs . . . 5

3 Δημιουργία και Εφαρμογή Νευρωνικού Δικτύου Kolmogorov-Arnold **6**
3.1 Δημιουργία Κώδικα . . . 6
3.1.1 Δημιουργία Splines . . . 6
3.1.2 Δημιουργία Δυναμικού Επιπέδου KAN . . . 6
3.2 Εφαρμογή σε Δεδομένα . . . 7
3.2.1 Προσομοιωμένα Δεδομένα . . . 7
3.2.2 Πραγματικά Δεδομένα . . . 8

4 Συμπεράσματα **9**

Γλωσσάρι **10**

Βιβλιογραφία **11**

1 Εισαγωγή

1.1 Τι είναι τα Splines

Στα μαθηματικά τα splines αποτελούν έναν τρόπο προσέγγισης δεδομένων στην θέση πολυωνυμικών συναρτήσεων υψηλού βαθμού. Βάσει ορισμού τα splines αποτελούν μια τμηματικά πολυωνυμική συνάρτηση[2] στην οποία τα δεδομένα αντί να περιγράφονται από μία ενιαία συνάρτηση, χωρίζονται σε έναν συγκεκριμένο αριθμό τμημάτων i. Στην συνέχεια τα δεδομένα που ανήκουν σε κάθε τμήμα προσεγγίζονται από επιμέρους πολυωνυμικές συναρτήσεις, οι οποίες είναι μικρότερου αλλά κοινού βαθμού p. Η συνάρτηση που εκτείνεται σε $p+1$ τμήματα ονομάζεται B-spline (ή Basis spline) και η γεωμετρική της μορφή εξαρτάται από τον βαθμό p των πολυωνυμικών συναρτήσεων. Έτσι τα δεδομένα στο σύνολό τους προσεγγίζονται από το τελικό spline το οποίο απαρτίζεται από τα B-splines.

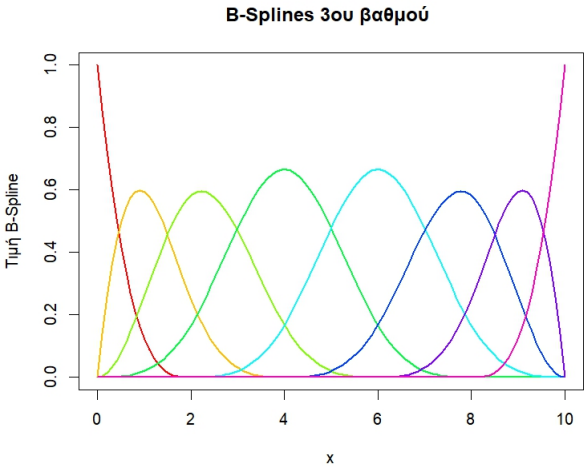
Τα B-splines χρειάζεται να τηρούν κάποιες προϋποθέσεις προκειμένου η τελική καμπύλη να είναι συνεχής, δηλαδή μία ενιαία καμπύλη. Συγκεκριμένα στα σημεία διαχωρισμού σε τμήματα, τα οποία σημεία ονομάζονται κόμβοι και συμβολίζονται ως t_i, απαιτείται οι γειτονικές συναρτήσεις βαθμού p να ταυτίζονται στις παραγώγους τους έως και τάξης $p-1$[2]. Έτσι επιτυγχάνεται η τελική καμπύλη να είναι συνεχώς παραγωγίσιμη σε όλο το διάστημα.

Εφόσον τηρούνται οι προϋποθέσεις τότε η τελική συνάρτηση spline δίνεται από τον τύπο:

$$S(x) = \sum_i c_i B_{i,p}(x)$$

Όπου $S(x)$ είναι το spline, $B_{i,p}(x)$ είναι το i-οστό B-spline βαθμού p, c_i είναι το βάρος του i-οστού B-spline και x τα δεδομένα[2]. Η τελική καμπύλη δημιουργείται βάσει των B-splines πολλαπλασιασμένα με τα κατάλληλα βάρη.

Επομένως, προκύπτει πως αντί να απαιτείται μια πολύπλοκη συνάρτηση για την περιγραφή των δεδομένων, είναι εφικτό να προσεγγιστούν από ένα σταθμισμένο άθροισμα πολυωνύμων μικρότερου βαθμού.



Σχήμα 1: Διάγραμμα B-splines 3ου βαθμού

Όπως φαίνεται στο διάγραμμα τα B-splines 3ου βαθμού παίρνουν καμπανοειδές σχήμα. Το φαινόμενο αυτό συμβαίνει καθώς απαιτούμε οι συναρτήσεις να έχουν μεταξύ τους ίδιες τις πρώτες και δεύτερες παραγώγους.

1.2 Τι είναι το Θεώρημα Kolmogorov-Arnold

Το θεώρημα Kolmogorov-Arnold δημιουργήθηκε το 1957 από τους μαθηματικούς Andrey Kolmogorov και Vladimir Arnold[5]. Δηλώνει πως κάθε συνεχής πολυμεταβλητή συνάρτηση $f(x_1, \ldots, x_d)$ η οποία είναι ορισμένη στο πεδίο $[0, 1]^d$ μπορεί να αναπαρασταθεί ακριβώς, ως σύνθεση συνεχών συναρτήσεων μίας μεταβλητής και πράξεων πρόσθεσης μέσω του ακόλουθου τύπου[8]:

$$f(x_1, \ldots, x_d) = \sum_{q=0}^{2d} g_q \left(\sum_{p=1}^{d} \psi_{p,q}(x_p) \right)$$

Ο τύπος εξηγεί πως μπορούμε να ορίσουμε μία συνάρτηση $\psi_{p,q}$ για κάθε μια μεταβλητή x_p με $p = 1 \ldots d$. Οι συναρτήσεις ψ είναι μαθηματικές συναρτήσεις οι οποίες δουλεύουν σαν έναν αλγόριθμο κρυπτογράφησης ψηφίων. Έστω ότι $x_1 = 0,123$, τότε το ψ σαν δουλειά έχει να ανακατανέμει τα ψηφία του x με μηδενικά ενδιάμεσα από κάθε ψηφίο. Έτσι στο άθροισμα όλων των ψ, δεν αθροίζεται κανένα ψηφίο με κάποιο άλλο μεταξύ των $\psi(x)$. Στο $\psi_{p,q}$ ο δείκτης p σχετίζεται με τον αριθμό των μεταβλητών x που έχουμε ενώ ο δείκτης q δείχνει πόσα διαφορετικά σετ συναρτήσεων ψ θα πάρουμε. Συγκεκριμένα ο δείκτης q παίρνει $2d + 1$ τιμές.

Η ανάγκη για πολλά σετ συναρτήσεων ψ υπάρχει προκειμένου να αποφύγουμε το ενδεχόμενο το άθροισμα κάποιων $\psi(x)$ να βγάζουν το ίδιο αποτέλεσμα για διαφορετικά σημεία. Στο ενδεχόμενο ότι γίνεται αυτό, το σύστημα μπερδεύεται και δεν αναγνωρίζει ότι το ίδιο αποτέλεσμα προέρχεται από δύο διαφορετικά σημεία. Η επιλογή του αριθμού $q = 2d + 1$ βασίζεται στο τοπολογικό Θεώρημα Menger-Nöbeling και μας προσφέρει τον κατάλληλο αριθμό ψ ώστε να αποφύγουμε το σφάλμα[4].

Τέλος κάθε $q = 0 \ldots 2d$ άθροισμα των $\psi_{p,q}(x_p)$ χρησιμοποιείται ως μεταβλητή της συνάρτησης g_q. Η συνάρτηση αυτή είναι συγκεκριμένη και εξαρτάται από την φύση της $f(x_1, \ldots, x_d)$. Το τελικό αποτέλεσμα αναπαριστά την αρχική συνάρτηση $f(x_1, \ldots, x_d)$.

1.2.1 Αδυναμίες του Θεωρήματος Kolmogorov-Arnold

Στα μαθηματικά συναρτήσεις όπως η ψ ονομάζονται μορφοκλασματικές. Οι συναρτήσεις αυτού του είδους είναι συχνά μη-παραγωγίσιμες συναρτήσεις καθώς δεν είναι ομαλές παρόλο που είναι συνεχείς. Παράδειγμα έλλειψης ομαλότητας αποτελεί η συνάρτηση $f(x) = |x|$ η οποία στο σημείο $x = 0$ δεν είναι ομαλή και άρα, ενώ είναι συνεχής, δεν είναι παραγωγίσιμη. Οι μορφοκλασματικές συναρτήσεις ωστόσο, καθώς υπάρχει έλλειψη ομαλότητας καθίστανται μη-παραγωγίσιμες συναρτήσεις σε όλο το φάσμα τους [3].

Ακόμη ένα μειονέκτημα του Θεωρήματος Kolmogorov-Arnold αποτελεί η μεγάλη ευαισθησία των συναρτήσεων ψ σε αλλαγές των δεδομένων μέσω θορύβου [3] καθώς οι συναρτήσεις ψ προσομοιάζουν την ανακατανομή των ψηφίων των δεδομένων x.

Τέλος, η πολυπλοκότητα εύρεσης της κατάλληλης εξωτερικής συνάρτησης g [6] σε συνδυασμό με την μορφοκλασματική μορφή των συναρτήσεων ψ και την ευαισθησία των δεδομένων σε αλλαγές έθεταν το θεώρημα ως μη πρακτικό.

2 Νευρωνικά Δίκτυα Kolmogorov-Arnold

2.1 Δημιουργία Νευρωνικών Δικτύων Kolmogorov-Arnold

Η ιδέα εφαρμογής του Θεωρήματος Kolmogorov-Arnold για τη δημιουργία μιας νέας αρχιτεκτονικής νευρωνικών δικτύων είχε δοκιμαστεί στο παρελθόν[3, 6]. Με επιτυχή εφαρμογή του θεωρήματος θα βρισκόταν ένας τρόπος προσέγγισης των πολύπλοκων συναρτήσεων που υπολόγιζαν τα κλασικά Νευρωνικά Δίκτυα τύπου MLPs με αποτέλεσμα την αύξηση της ακρίβειας. Ωστόσο, λόγω της μη-παραγωγίσιμης φύσης των συναρτήσεων που προέκυπταν, οι οποίες καθιστούσαν την εκπαίδευση του μοντέλου αδύνατη, καθώς και της αδυναμίας γενίκευσης, ο συνδυασμός αυτός δεν ήταν επιτυχής.

Τα προβλήματα αυτά επιλύθηκαν με τον συνδυασμό του Θεωρήματος Kolmogorov-Arnold και των splines[7]. Συγκεκριμένα, αντικαθιστώντας τις συναρτήσεις $\psi_{p,q}$ και g_q με splines 3ου βαθμού προσφέρουμε στο μοντέλο συναρτήσεις παραγωγίσιμες και εύκολα υπολογίσιμες, ακυρώνοντας τις αδυναμίες του θεωρήματος και καθιστώντας το ιδανικό για χρήση. Ο λόγος για την επιλογή splines 3ου βαθμού είναι ότι εγγυώνται συνέχεια μέχρι και τη δεύτερη παράγωγο, δηλαδή μας εξασφαλίζεται όχι μόνο η συνεχής ροή της καμπύλης, αλλά και η ομαλή μεταβολή της καμπυλότητάς της. Έτσι δημιουργήθηκαν τα Νευρωνικά Δίκτυα Kolmogorov-Arnold (ή KANs).

2.2 Αρχιτεκτονική των KANs

Η μαθηματική δομή των νευρωνικών δικτύων Kolmogorov-Arnold αντλείται από την μαθηματική διατύπωση του θεωρήματος Kolmogorov-Arnold. Με περαιτέρω ανάλυση του Θεωρήματος παρατηρούμε πως ο μαθηματικός του τύπος φέρει ομοιότητες με τη δομή νευρωνικού δικτύου ενός κρυφού επιπέδου[1] (το εσωτερικό άθροισμα είναι το κρυφό επίπεδο και το εξωτερικό άθροισμα το επίπεδο εξόδου).

$$f(x_1, \ldots, x_d) = \sum_{q=0}^{2d} g_q \left(\sum_{p=1}^{d} \psi_{p,q}(x_p) \right)$$

Μαθηματικός τύπος Θεωρήματος Kolmogorov-Arnold

$$y = \sigma \left(\sum (w \cdot x) \right)$$

Εξίσωση κρυφού επιπέδου MLP

Ωστόσο, συγκρίνοντας τους δύο τύπους βλέπουμε ορισμένες διαφορές οι οποίες αλλάζουν τη φύση των νευρωνικών δικτύων Kolmogorov-Arnold από τα κλασικά MLP.

1. **Οι ακμές**: Στα κλασικά MLP οι ακμές, δηλαδή οι πράξεις εντός του αθροίσματος, εκτελούν απλούς γραμμικούς υπολογισμούς πολλαπλασιάζοντας τα δεδομένα x με ορισμένα βάρη w. Ωστόσο στον τύπο του Θεωρήματος Kolmogorov-Arnold βλέπουμε πως, εντός του αθροίσματος πραγματοποιούνται μη γραμμικοί υπολογισμοί στη μορφή των συναρτήσεων $\psi_{p,q}$ ή των splines στα Νευρωνικά Δίκτυα Kolmogorov-Arnold[7].

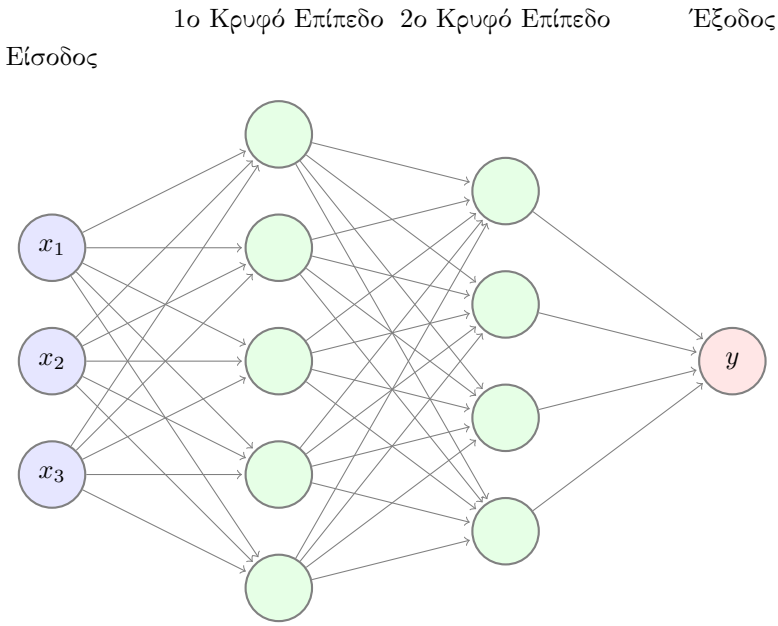
2. **Οι κόμβοι**: Οι κόμβοι στα MLP δέχονται τα δεδομένα και στην συνέχεια εφαρμόζουν σε αυτά μια συνάρτηση ενεργοποίησης σ. Αντίθετα στο Θεώρημα Kolmogorov-Arnold οι κόμβοι έχουν καθαρή αθροιστική λειτουργία και δεν εφαρμόζουν κάποια συνάρτηση ενεργοποίησης[7].

Στα KANs κάθε κρυφό επίπεδο συμβολίζεται ως Φ το οποίο αποτελεί έναν πίνακα συναρτήσεων ο οποίος περιέχει τα splines των ακμών $\varphi_{i,j}(x_i)$.

Οι διαστάσεις του πίνακα είναι $n_{in} \times n_{out}$ όπου n_{in} ο αριθμός των κόμβων εισόδου και n_{out} ο αριθμός των κόμβων εξόδου. Ο αριθμός των κόμβων εισόδου είναι ο αριθμός των μεταβλητών που έχουμε εξαρχής.

Ο κάθε κόμβος υπολογίζεται από την εξίσωση $x_j = \sum_{i=1}^{n_{in}} \phi_{i,j}(x_i)$ όπου το $\varphi_{i,j}$ αποτελεί το spline της συγκεκριμένης ακμής που ενώνει τον κόμβο x_i με τον κόμβο x_j. Το spline υπολογίζεται από την εξίσωση $\phi_{i,j}(x) = \sum_{k=1}^{K} c_k B_k(x)$ όπου $B_k(x)$ είναι η συνάρτηση βάσης (B-spline) και c_k το αντίστοιχο βάρος.

Για την δημιουργία KAN με περισσότερα από ένα κρυφά επίπεδα αρκεί η σύνθεση των πινάκων συναρτήσεων Φ για κάθε επίπεδο: $\text{KAN}(x) = (\Phi_L \circ \Phi_{L-1} \circ \cdots \circ \Phi_1)(x)$, όπου L ο αριθμός των κρυφών επιπέδων.



Σχήμα 3: Αρχιτεκτονική ενός Βαθέος Δικτύου Kolmogorov-Arnold (Deep KAN) με διαστάσεις $[3, 5, 4, 1]$. Στα KANs, οι γραμμές (ακμές) αναπαριστούν τις μη-γραμμικές συναρτήσεις ϕ (τα splines), ενώ οι κόμβοι επιτελούν απλή άθροιση των σημάτων που λαμβάνουν.

Στο παραπάνω διάγραμμα οπτικοποιείται η αρχιτεκτονική ενός Βαθέος Δικτύου Kolmogorov-Arnold (βαθέος καθώς αποτελείται από παραπάνω από ένα κρυφό επίπεδο). Το δίκτυο αποτελείται από 3 μεταβλητές εισόδου και μία μεταβλητή εξόδου. Το πρώτο και δεύτερο κρυφό επίπεδο έχουν 5 και 4 μεταβλητές, δηλαδή κόμβους, αντίστοιχα. Ο πίνακας Φ_1 διαστάσεων 3×5 αποτελείται από τα $3 \times 5 = 15$ splines που υπάρχουν στις 15 ακμές μεταξύ των κόμβων εισόδου και των κόμβων του πρώτου κρυφού επιπέδου. Ομοίως οι πίνακες Φ_2 και Φ_3 διαστάσεων 5×4 και 4×1 αντίστοιχα αποτελούνται από 20 και 4 splines ο καθένας. Το τελικό αποτέλεσμα y υπολογίζεται μέσω του $\text{KAN}(x_1, x_2, x_3) = \Phi_3 \circ \Phi_2 \circ \Phi_1$.

2.3 Διαφορές Αρχιτεκτονικών και Σύγκριση KANs με MLPs

2.3.1 Διαφορές Αρχιτεκτονικών

Όπως αναφέρθηκε προηγουμένως, στα KANs οι μη γραμμικοί υπολογισμοί πραγματοποιούνται στις ακμές και οι γραμμικοί υπολογισμοί, συγκεκριμένα οι αθροίσεις, στους κόμβους. Οι λειτουργίες των ακμών και των κόμβων είναι πρακτικά ανεστραμμένες σε σύγκριση με τις λειτουργίες τους στα MLPs[7]. Πιο αναλυτικά, στα MLPs οι ακμές αναλαμβάνουν τους γραμμικούς υπολογισμούς, δηλαδή τους πολλαπλασιασμούς με σταθερά βάρη, ενώ οι κόμβοι περιέχουν τη συνάρτηση ενεργοποίησης.

2.3.2 Σύγκριση KANs με MLPs

Η διαφορά μεθόδου επεξεργασίας των δεδομένων στις δυο αρχιτεκτονικές οδηγεί σε διαφορές, τόσο στις επιδόσεις τους όσο και στον τρόπο και τη μέθοδο ερμηνείας τους.

1. Ακρίβεια Μοντέλου

   Έχει αποδειχθεί ότι ένα KAN μπορεί να πετύχει καλύτερη ακρίβεια από ένα MLP χρησιμοποιώντας μικρότερο αριθμό παραμέτρων[7].

2. Ταχύτεροι Νόμοι Κλιμάκωσης

   Η προσθήκη παραμέτρων σε ένα KAN οδηγεί σε μεγαλύτερη πτώση του σφάλματος γενίκευσης από ότι θα οδηγούσε η ίδια προσθήκη σε ένα MLP[7]. Συγκεκριμένα το σφάλμα γενίκευσης στα KAN μειώνεται με ρυθμό $\mathcal{O}(N^{-(k+1)})$ [7] ενώ στα MLP το σφάλμα μειώνεται με ρυθμό $\mathcal{O}(N^{-2k/d})$[9].

   Άρα ο ρυθμός μείωσης του σφάλματος στα KAN εξαρτάται από το μέγεθος του δικτύου N και από τον βαθμό των splines k ενώ στα MLP εξαρτάται από το μέγεθος του δικτύου N, την ομαλότητα της πραγματικής συνάρτησης k και από τον αριθμό μεταβλητών εισόδου d.

3. Τοπικό Στήριγμα

   Τα MLP σε καινούργια δεδομένα απαιτείται να αλλάξουν τα βάρη τους καθολικά, καθώς οι συναρτήσεις ενεργοποίησης έχουν καθολικό στήριγμα. Αντιθέτως, τα KAN, λόγω της φύσης των splines που απαρτίζονται από B-splines, μπορούν να προσαρμόσουν μόνο το βάρος του B-spline το οποίο περιέχει αλλαγές στα δεδομένα. Έτσι, διατηρούνται τα υπόλοιπα βάρη αμετάβλητα[7].

4. Ερμηνευσιμότητα

   Στα KAN δίνεται η δυνατότητα αφαίρεσης splines ύστερα από την εκπαίδευση καθώς και στην συνέχεια η εξαγωγή του μαθηματικού τύπου που περιγράφει τα δεδομένα[7].

5. Χρόνος Εκπαίδευσης

   Ανά παράμετρο, ένα KAN μπορεί να είναι έως και 10 φορές πιο αργό στην εκπαίδευσή του από ότι ένα MLP λόγω των μη-γραμμικών συναρτήσεων βάσης που υπολογίζουν τα KAN έναντι των πράξεων πινάκων που υπολογίζουν τα MLP[7].

3 Δημιουργία και Εφαρμογή Νευρωνικού Δικτύου Kolmogorov-Arnold

Μέσω της γλώσσας R και με χρήση της βιβλιοθήκης torch θα δημιουργήσουμε ένα Νευρωνικό Δίκτυο Kolmogorov-Arnold το οποίο θα εφαρμόσουμε πάνω σε προσομοιωμένα καθώς και πραγματικά δεδομένα.

3.1 Δημιουργία Κώδικα

3.1.1 Δημιουργία Splines

Προκειμένου να δημιουργήσουμε ένα Νευρωνικό Δίκτυο Kolmogorov-Arnold αρχικά χρειαζόμαστε μία συνάρτηση υπολογισμού splines. Την συνάρτηση αυτή θα την δημιουργήσουμε βασισμένοι στον αναδρομικό αλγόριθμο Cox-de Boor[2]:

$$B_{i,0}(x) = \begin{cases} 1, & \text{εάν } t_i \leq x < t_{i+1} \\ 0, & \text{διαφορετικά} \end{cases}$$

Βάση της αναδρομής $p = 0$

$$B_{i,p}(x) = \frac{x - t_i}{t_{i+p} - t_i} B_{i,p-1}(x) + \frac{t_{i+p+1} - x}{t_{i+p+1} - t_{i+1}} B_{i+1,p-1}(x)$$

Αναδρομικό Βήμα $p > 0$

Ο παραπάνω μαθηματικός τύπος εξηγεί πώς υπολογίζονται τα B-splines. Όταν θέλουμε να υπολογίσουμε ένα B-spline μηδενικού βαθμού χρησιμοποιούμε τη βάση της αναδρομής. Για B-splines βαθμού $p > 0$ χρησιμοποιείται το αναδρομικό σκέλος του τύπου (δεξιά) το οποίο αποτελείται από δύο τμήματα. Στην ουσία ο συγκεκριμένος τύπος εξηγεί πως για τον υπολογισμό ενός B-spline βαθμού $p > 0$ χρησιμοποιούμε δυο B-splines βαθμού $p-1$. Εφόσον κάθε B-spline βαθμού $p > 0$ υπολογίζεται από δύο B-spline ενός βαθμού μικρότερο, η διαδικασία επαναλαμβάνεται μέχρι να απαιτείται ο υπολογισμός ενός B-spline μηδενικού βαθμού.

Η επιρροή του κάθε κόμβου προσαρμόζεται βάσει του πόσο πλησιάζουμε τα όρια των τμημάτων, όπως φαίνεται από τους αριθμητές $x - t_i$ και $t_{i+p+1} - x$. Καθώς η μεταβλητή x κινείται στον οριζόντιο άξονα με κατεύθυνση από αριστερά προς τα δεξιά η επιρροή του πρώτου κλάσματος αυξάνεται ενώ η επιρροή του δεύτερου μειώνεται. Σκοπός αυτής της αυξομείωσης είναι να επιτευχθεί μια γραμμική παρεμβολή για την δημιουργία μιας λείας καμπύλης.

3.1.2 Δημιουργία Δυναμικού Επιπέδου KAN

Αρχικά ορίζουμε τα όρια του διαστήματος και στην συνέχεια δημιουργούμε μια συνάρτηση η οποία χωρίζει το διάστημα σε τμήματα βάσει του αριθμού κόμβων της επιλογής μας. Ακόμη προσθέτουμε βοηθητικούς κόμβους στα άκρα του διαστήματος για την ορθή αξιολόγηση των πολυωνύμων. Στη συνέχεια ορίζουμε τον αριθμό των B-splines που θα χρειαστούμε τον οποίο υπολογίζουμε από τον τύπο $p + k$ όπου p ο αριθμός των τμημάτων και k ο βαθμός των B-spline. Έπειτα δημιουργούμε τανυστές για τα βάρη των B-spline καθώς και της συνάρτησης SiLU. Η συνάρτηση SiLU χρησιμοποιείται στα πρώιμα στάδια της εκπαίδευσης όπου τα βάρη των B-splines είναι ανεκπαίδευτα, προκειμένου να μην καταρρεύσει ο αλγόριθμος.

Ύστερα ορίζουμε το forward pass στο οποίο δημιουργούμε τα B-splines για τα δεδομένα μας και πολλαπλασιάζουμε με τα κατάλληλα βάρη τα B-splines και την συνάρτηση SiLU. Τέλος, τα σήματα της SiLU και των B-splines προστίθενται για να σχηματίσουν τη συνολική ενεργοποίηση κάθε ακμής, η οποία καταλήγει στον κάθε κόμβο όπου και αθροίζεται με τις υπόλοιπες εισερχόμενες συνδέσεις.

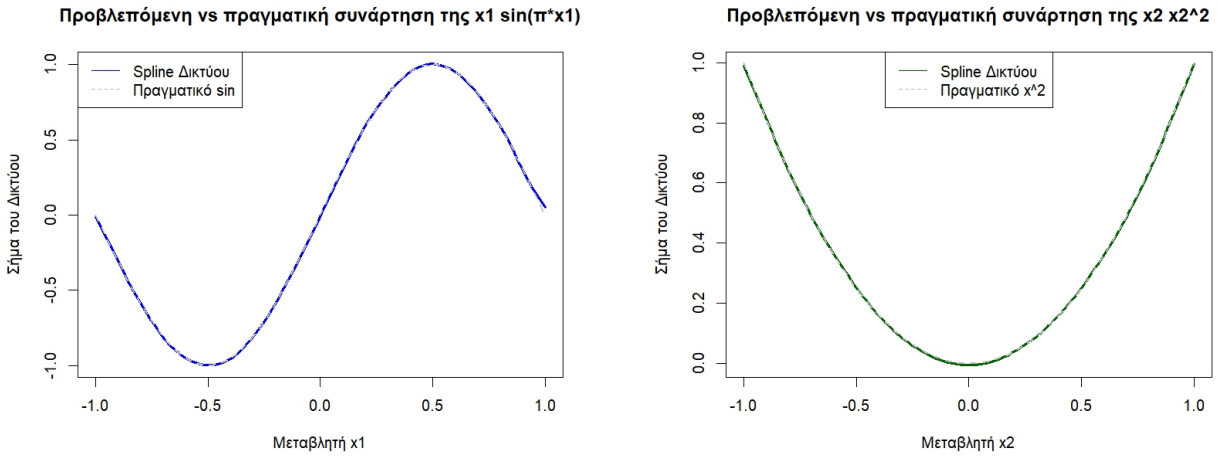
Αφού έχουν οριστεί όλες οι αναγκαίες συναρτήσεις για την δημιουργία ενός επιπέδου KAN, ορίζουμε την αρχιτεκτονική της επιλογής μας, δηλαδή σε πόσα τμήματα να χωρίζεται το διάστημα, τον βαθμό των B-splines, πόσα επίπεδα επιθυμούμε να έχει το δίκτυο μας καθώς και πόσους κόμβους να περιέχει το κάθε επίπεδο.

3.2 Εφαρμογή σε Δεδομένα

3.2.1 Προσομοιωμένα Δεδομένα

Χρησιμοποιώντας προσομοιωμένα δεδομένα θα αναδείξουμε την ικανότητα Συμβολικής Παλινδρόμησης του μοντέλου. Δηλαδή να μπορούμε να δούμε την συνάρτηση από την οποία περιγράφονται τα δεδομένα.

Ξεκινάμε δημιουργώντας δυο μεταβλητές x_1 και x_2 με τυχαίες τιμές μεταξύ του διαστήματος $[-1, 1]$ η κάθε μια. Στην συνέχεια δημιουργούμε την συνάρτηση $y = \sin(\pi x_1) + x_2^2$ την οποία όμως δεν παρέχουμε στο δίκτυο μας. Στο δίκτυο παρέχουμε μόνο τα δεδομένα x_1 και x_2 καθώς και το τελικό αποτέλεσμα y. Συνεχίζουμε ορίζοντας τις παραμέτρους του δικτύου και έπειτα ξεκινάμε την εκπαίδευση του ενώ ταυτόχρονα καταγράφουμε την πτώση του σφάλματος. Προκειμένου να εξάγουμε την επιμέρους συνάρτηση της κάθε μεταβλητής χρειάζεται να την απομονώσουμε, δηλαδή για κάθε μεταβλητή που ελέγχουμε ορίζουμε την άλλη ως μηδενική αφού το μοντέλο έχει ήδη εκπαιδευτεί και με τις δύο μαζί. Οι συναρτήσεις των μεταβλητών:



(α) Ανακάλυψη της συνάρτησης $\sin(\pi x_1)$

(β) Ανακάλυψη της συνάρτησης x_2^2

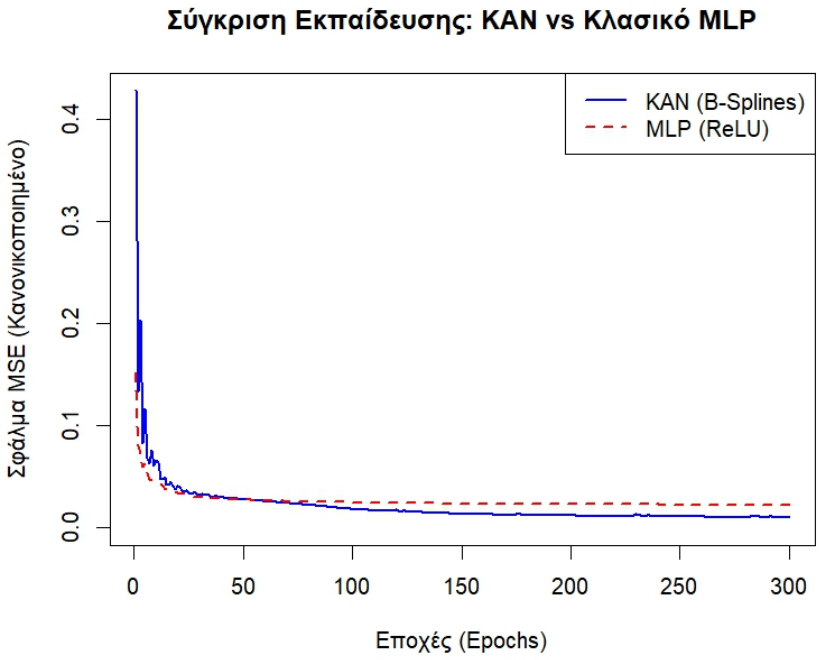
Σχήμα 5: Ικανότητα Συμβολικής Παλινδρόμησης των δικτύων KAN

Όπως φαίνεται από τα διαγράμματα οι προβλεπόμενες καμπύλες των μεταβλητών x_1 και x_2 εφάπτονται πλήρως με τις πραγματικές συναρτήσεις των μεταβλητών. Με αυτή την μέθοδο, ενώ στα παραδοσιακά δίκτυα γνωρίζουμε σε θεωρητικό επίπεδο πως η μεταβλητή y εξαρτάται από τα x_1 και x_2, τώρα μπορούμε να ανακατασκευάσουμε με ακρίβεια την τελική συνάρτηση που ακολουθούν τα δεδομένα μας μέσω της οπτικοποίησης splines.

3.2.2 Πραγματικά Δεδομένα

Χρησιμοποιώντας πραγματικά δεδομένα θα συγκρίνουμε το σφάλμα (MSE) του δικτύου KAN με εκείνο ενός δικτύου MLP. Το σετ δεδομένων αποσκοπεί στην κοστολόγηση σπιτιών και απαρτίζεται από 13 μεταβλητές μία εκ των οποίων η εξαρτημένη μεταβλητή price. Οι υπόλοιπες 12 αποτελούν τις ανεξάρτητες μεταβλητές από τις οποίες 5 είναι αριθμητικές και οι άλλες 7 κατηγορικές.

Αφού το σετ δεδομένων καθαριστεί και οι μεταβλητές κανονικοποιηθούν, συνεχίζουμε με την εκπαίδευση των δικτύων, τα οποία έχουν τον ίδιο αριθμό κόμβων. Αξίζει να σημειωθεί πως ο χρόνος εκπαίδευσης του δικτύου KAN ήταν μεγαλύτερος του MLP. Ωστόσο, αυτή η παρατήρηση δεν αποτελεί βάσιμη σύγκριση, καθώς κριτήριο του χρόνου εκπαίδευσης αποτελεί ο συνολικός αριθμός εκπαιδεύσιμων παραμέτρων και όχι των κόμβων. Η καμπύλη του σφάλματος παρατίθεται στο παρακάτω διάγραμμα.



Σχήμα 6: Διάγραμμα Σύγκρισης Σφάλματος KAN vs MLP

Όπως φαίνεται από το διάγραμμα, η τελική τιμή στην οποία συγκλίνει το σφάλμα του δικτύου MLP είναι μεγαλύτερη από εκείνη του δικτύου KAN. Στην πραγματικότητα, το δίκτυο KAN περιέχει περισσότερες παραμέτρους απ' ό,τι το δίκτυο MLP. Ωστόσο, το γεγονός αυτό αποτελεί πλεονέκτημα για το δίκτυο KAN καθώς, από το ίδιο σετ δεδομένων δημιούργησε περισσότερες εκπαιδεύσιμες παραμέτρους απ' ό,τι το δίκτυο MLP και έτσι, μπόρεσε να επεξεργαστεί την πληροφορία πιο αποδοτικά. Ως αποτέλεσμα αυτού, ενώ κάθε επίπεδο μεταξύ των δικτύων έχει τον ίδιο αριθμό κόμβων, το δίκτυο KAN οδήγησε σε καλύτερα αποτελέσματα.

4 Συμπεράσματα

Ο στόχος της παρούσας αναφοράς ήταν η ανάδειξη των νευρωνικών δικτύων KAN, μιας αρχιτεκτονικής διαφορετικής από τα παραδοσιακά νευρωνικά δίκτυα. Αναλύοντας το μαθηματικό τους υπόβαθρο, κατανοήσαμε τον διαφορετικό τρόπο επεξεργασίας των δεδομένων που ακολουθεί η συγκεκριμένη μέθοδος, ενώ στη συνέχεια συζητήσαμε και παρουσιάσαμε τις βασικές της ιδιότητες σε προσομοιωμένα, καθώς και σε πραγματικά δεδομένα.

Με περαιτέρω ανάλυση και έρευνα της συγκεκριμένης αρχιτεκτονικής, με σκοπό τη βελτιστοποίηση της απόδοσής της, τα KANs αναμένεται να αποτελέσουν μια ισχυρή, σύγχρονη εναλλακτική στον ευρύτερο τομέα της Τεχνητής Νοημοσύνης. Ειδικότερα, χάρη στην υψηλή τους ακρίβεια και, κυρίως, την ερμηνευσιμότητά τους, μπορούν να προσφέρουν λύσεις σε κρίσιμους τομείς, παρέχοντας τόσο υψηλή απόδοση όσο και διαφάνεια.

Προς το παρόν, εάν κάποιος επιθυμεί γρήγορα αποτελέσματα, θα επωφεληθεί περισσότερο από τη χρήση των MLPs. Εάν, όμως, επιδιώκεται το βέλτιστο δυνατό αποτέλεσμα, τα KANs έχουν αποδειχθεί αντάξια ή και ανώτερα.

Γλωσσάρι

Όρος	Ορισμός
B-spline (Basis spline)	Μια συνάρτηση η οποία εκτείνεται σε συγκεκριμένο αριθμό τμημάτων και χρησιμοποιείται ως βάση για τη δημιουργία της τελικής καμπύλης (spline).
MLP (Multi-Layer Perceptron)	Παραδοσιακή αρχιτεκτονική τεχνητών νευρωνικών δικτύων όπου οι μη-γραμμικοί υπολογισμοί εφαρμόζονται στους κόμβους (μέσω συναρτήσεων ενεργοποίησης), ενώ οι ακμές εκτελούν απλούς γραμμικούς υπολογισμούς.
SiLU (Sigmoid Linear Unit)	Ειδική συνάρτηση ενεργοποίησης που χρησιμοποιείται στα αρχικά στάδια εκπαίδευσης των δικτύων KAN, προκειμένου να σταθεροποιήσει τον αλγόριθμο όταν τα βάρη των B-splines είναι ακόμα ανεκπαίδευτα.
Spline	Μαθηματική συνάρτηση η οποία ορίζεται τμηματικά από πολυώνυμα μικρότερου βαθμού, επιτρέποντας την προσαρμογή σε δεδομένα με υψηλή ακρίβεια και εξασφαλίζοντας τη συνεχή ροή της καμπύλης.
Αλγόριθμος Cox-de Boor	Ένας αποδοτικός αναδρομικός αλγόριθμος που χρησιμοποιείται για τον υπολογισμό των συναρτήσεων βάσης (B-splines) οποιουδήποτε βαθμού.
Κρυφό Επίπεδο (Hidden Layer)	Το ενδιάμεσο επίπεδο ενός νευρωνικού δικτύου, μεταξύ εισόδου και εξόδου.
Μέσο Τετραγωνικό Σφάλμα (MSE)	Μέτρο αξιολόγησης (Mean Squared Error) που υπολογίζει τον μέσο όρο των τετραγώνων των διαφορών μεταξύ των πραγματικών και των προβλεπόμενων τιμών.
Μορφοκλασματική συνάρτηση (Fractal function)	Μια συνάρτηση η οποία, ενώ είναι συνεχής, στερείται ομαλότητας, καθιστώντας την μη-παραγωγίσιμη σε όλο της το φάσμα.
Νόμοι Κλιμάκωσης (Scaling Laws)	Μαθηματικοί κανόνες που περιγράφουν τον ρυθμό με τον οποίο μειώνεται το σφάλμα ενός μοντέλου (σφάλμα γενίκευσης) καθώς αυξάνεται ο αριθμός των παραμέτρων του.
Συμβολική Παλινδρόμηση (Symbolic Regression)	Η διαδικασία κατά την οποία ένα μοντέλο ανακαλύπτει και εξάγει τον ακριβή μαθηματικό τύπο (συνάρτηση) που περιγράφει τα δεδομένα.
Συνάρτηση Ενεργοποίησης (Activation Function)	Μια μαθηματική συνάρτηση που παραδοσιακά εφαρμόζεται στους κόμβους των MLPs. Στα δίκτυα KAN, συναρτήσεις όπως η SiLU χρησιμοποιούνται επικουρικά στα πρώιμα στάδια εκπαίδευσης των ακμών.
Τανυστής (Tensor)	Πολυδιάστατος πίνακας αριθμών που αποτελεί τη βασική δομή δεδομένων σε βιβλιοθήκες μηχανικής μάθησης (όπως η torch) για τον υπολογισμό και την αποθήκευση των βαρών του δικτύου.

Βιβλιογραφία

[1] Yoshua Bengio, Ian Goodfellow, Aaron Courville, et al. *Deep learning*, volume 1. MIT press Cambridge, MA, USA, 2017.

[2] Carl De Boor and Carl De Boor. *A practical guide to splines*, volume 27. springer New York, 1978.

[3] Federico Girosi and Tomaso Poggio. Representation properties of networks: Kolmogorov's theorem is irrelevant. *Neural Computation*, 1(4):465–469, 1989.

[4] Witold Hurewicz and Henry Wallman. Dimension theory (pms-4). 2015.

[5] Andrey Nikolaevich Kolmogorov. On the representation of continuous functions of many variables by superposition of continuous functions of one variable and addition. *Doklady Akademii Nauk SSSR*, 114(5):953–956, 1957. [In Russian].

[6] Věra Krková. Kolmogorov's theorem and multilayer neural networks. *Neural networks*, 5(3):501–506, 1992.

[7] Ziming Liu, Yixuan Wang, Sachin Vaidya, Fabian Ruehle, James Halverson, Marin Soljacic, Thomas Hou, and Max Tegmark. Kan: Kolmogorov–arnold networks. In *International conference on learning representations*, volume 2025, pages 70367–70413, 2025.

[8] Johannes Schmidt-Hieber. The kolmogorov–arnold representation theorem revisited. *Neural networks*, 137:119–126, 2021.

[9] Dmitry Yarotsky. Error bounds for approximations with deep relu networks. *Neural networks*, 94:103–114, 2017.